BGE-M3 RAG
전체 구성·데이터·평가 자료

기준: 2026-10-20 18:25 KST · 실제 실행 상태를 확인한 문서 갱신본

BAAI/bge-m3 · 1,024차원 · BM25 하이브리드 · 5432/toss_rag

항목	현재 값
데이터	상품 1,500 · 옵션 1,917 · 리뷰 46,100
BGE 벡터	114,106개 · 전체 네 카테고리 · ready
청킹	기존 v2 · 최대 96토큰 · overlap 없음
운영/품질 구분	BGE 전환 확인. 전체 추천 정확도는 별도 평가 필요.



현재 BGE API는 0.2.0이며 가격·재고·상품 유형의 이전 개선 기능이 모두 통합된 것은 아니다. 문서의 계약/제한을 함께 확인한다.

RAG 전체 자료 — BGE-M3 운영 기준

기준: **2026-10-20 18:25 KST**. 실제 컨테이너·HTTP 상태·실행 소스·DB를 읽어 갱신했다.

자료 바로가기

내용	문서
실제 BGE 구성·호출 흐름·메서드·LangChain	현재 RAG 구성
데이터셋·원본/옵션/리뷰·청크·벡터 저장	데이터셋과 저장 구조
96토큰 청킹·BGE 1,024차원·재임베딩·v2/v3	청킹과 임베딩
MiniLM/E5/BGE/Qwen 비교·비용·전체 전환 결과	모델 비교와 평가
현재 API 0.2.0 계약·Brain 연결·추천 정책 공백	API·Agent 연동
전체 원문·PDF·JSON·계약·과거 설계 찾기	전체 문서 목록
통합 보고서 인쇄·공유	BGE 전체 보고서 PDF
실행 상태·현재 요청 스키마	상태 증거, 요청 JSON Schema
원문 출처·버전·중복·SHA-256	source-manifest.json
실제 BGE 실행 소스 사본	소스 메타데이터

현재 구성 요약

항목	현재 확인 결과
모델	**BAAI/bge-m3**, dense **1,024차원**, 고정 revision
검색	**ParadeDB BM25 + BGE dense → 상품별 RRF(k=60)**
DB	**5432/toss_rag/rag**
데이터	test_items2: **1,500상품·1,917옵션·46,100리뷰**
BGE 벡터	**114,106개**, 전체 네 범주, scope=*, ready
청킹	기존 v2, **최대 96토큰**, overlap 없음. 재청킹 없이 BGE 재임베딩
입력 길이	현재 BGE 호출 최대 128토큰
기존 MiniLM	복구용 384차원 벡터 보존
LangChain	현재 BGE 계산은 **FlagEmbedding 직접 호출**. HTTP도 hybrid_search 직접 호출
API	현재 **0.2.0** 계약. 이전 0.3.0 확장 필드와 구분 필요
가격/재고·유형 검증	이전 추천 품질 브랜치 기능 전체가 현재 BGE 실행본에 통합된 것은 아님

현재 BGE 모델 적용은 확인됐다. 전체 카테고리의 추천 정확도는 별도 평가이며, beauty의 소규모 비교 점수를 전체 정확도로 표시하지 않는다.

이번 갱신에서 달라진 내용

1. 이전 14:47 MiniLM 상태를 **18:25 BGE 실제 운영 상태**로 갱신했다.

2. 전체 범주 BGE 벡터 114,106개와 모델 설정·현재 API를 재확인했다.

3. 구성도를 BgeM3Embedder/FlagEmbedding/별도 벡터 테이블 기준으로 수정했다.

4. 전체 적재·전환·복구 보고서와 실행 소스/요청 스키마를 추가했다.

5. API 계약·가격/재고·유형 검사 등 브랜치 간 기능 차이를 표시했다.

6. 기존 비교 결과는 그대로 보존하고 새 전체 적용 기록을 추가했다.

수집 범위

원문·평가·스키마·예제 **239개**, 발견 위치/버전 **300건**을 수록했다. 같은 내용의 중복 61건은 사본을 합쳤다. 새로 작성한 통합 요약·실행 증거·읽기용 소스는 이 원문 수에 포함하지 않는다.

현재 파일, Backend worktree들, 이전 프로젝트 worktree, 로컬 Git ref의 문서 버전, 사용자 첨부, 데이터 ZIP의 README/DDL/manifest를 조사했다. 외부 팀 문서 저장소나 모든 중간 Git 커밋까지 포함하는 전사 문서 목록은 아니다.

archive는 작성 당시 원문이다. **과거 MiniLM/0.3.0/PDF 설명을 현재 BGE 상태로 읽지 않는다.** 이전 자료는 14:47 상태 기록과 기존 ZIP으로 보존했다.

원본 데이터·전체 벡터 덤프·모델 가중치·실제 비밀 환경 파일은 새 문서 ZIP에 넣지 않았다. 특히 기존 test_items2 데이터 ZIP의 벡터는 MiniLM 384차원 스냅샷이며 최신 BGE 덤프로 바뀐 것이 아니다.

저장·반영 상태

문서 작업은 Backend **feature/rag-documentation-index**에 로컬 저장했다. 이 갱신에서 모델·서비스·DB를 수정하거나 새 검색 평가를 실행하지 않았다. BGE 전환은 기존 적용 기록과 현재 실행 증거로 확인했다.

문서의 새 커밋·GitHub 푸시·main 병합은 수행하지 않았다. 팀 Git 규칙은 정본을 따른다. 이후 모델·run·계약·청커가 바뀌면 이 목차와 현재 구성·증거·평가 문서를 함께 갱신한다.

현재 RAG 구성 — BGE-M3 운영 기준

확인 시각: 2026-10-20 18:25 KST. 통합 목차 · 실행 증거

1. 실제 실행 상태

항목	확인 결과
모델	BAAI/bge-m3, dense 1,024차원
revision	5617a9f61b028005a4858fdac845db406aefb181
입력 상한·실행	128토큰, CPU FlagEmbedding
검색	BM25 + BGE-M3 dense → 상품별 RRF(k=60)
컨테이너	product-rag-api, running
이미지	toss-ads-product-rag-service:rag-bge-m3-full-test-items2-252bc90
API	http://127.0.0.1:8002, POST /v1/rag/search, 버전 0.2.0
검색 DB	5432 / toss_rag / rag
데이터	test_items2, 1,500상품 / 46,100리뷰 / 114,106청크
선택 run	e925490f-4f34-4c03-9248-eb9ebdfcde48
BGE 프로필	scope=*, status=ready, 114,106벡터
범주	beauty, fashion, food, living
청킹	기존 v2 / 최대 96토큰 / overlap 없음
MiniLM	기존 384차원 114,106벡터는 복구용 보존

14:47 KST의 이전 자료는 MiniLM 실행을 기록했다. 이후 전체 BGE 적재·전환 기록이 생겼고, 이번 재확인에서도 BGE 실행 설정과 전체 벡터 수를 확인했다. 이번 문서 갱신 자체가 모델을 전환한 것은 아니다.

healthz는 HTTP 200, status=ok와 test_items2 버전·네 범주를 반환했다. 모델명은 healthz 응답에 직접 나오지 않으므로 컨테이너 설정·실행 코드·DB 프로필을 함께 확인했다.

2. 현재 검색 흐름

흐름도는 첫 장의 BGE 파이프라인과 동봉 Markdown의 Mermaid 원본을 함께 참고한다.

이번 확인은 RAG API·실행 소스·DB 메타데이터 범위다. Brain/웹/최종 LLM까지의 E2E나 새 검색 품질 평가를 실행하지 않았다. 이 API 자체는 답변 생성 LLM을 호출하지 않는다.

3. 메서드와 역할

문서 브랜치의 과거 src와 혼동하지 않도록 실행 컨테이너에서 읽은 소스 사본에 연결했다.

파일	메서드	역할
api.py	create_app, 검색 핸들러	모델/DB 구성, 검증, hybrid_search 직접 호출, HTTP 오류 변환
schemas.py	RagSearchRequest.model_validate	원문·query·category·가격 요청 형식·top_k 검증
embeddings.py	create_embedder	BGE이면 자체 어댑터, MiniLM이면 FastEmbed 생성

파일	메서드	역할
bge_m3.py	embed_query, embed_documents	고정 revision의 FlagEmbedding dense 계산. sparse/ColBERT 비활성
retriever.py	bge_profile_ready	전체 범위·ready·차원·입력 길이·revision·실제 벡터 수 검사
store.py	active_run	active 중 완료/시작 시각 기준 최신 run 선택
store.py	search_bm25, search_embedding_vector	ParadeDB BM25와 별도 BGE 벡터 테이블 검색
retriever.py	hybrid_search	채널 결합·상품 RRF·원문 근거 선택

소스 출처/해시: 실행 소스 메타데이터.

4. 랭킹·조건 처리의 실제 범위

항목	현재 BGE 실행본
채널 깊이	각 채널 **20청크**. 50개 서로 다른 상품 확보 방식은 아님
RRF	상품별 각 채널 최고 청크 순위의 1/(60+rank) 합
동점	category, product_id로 정렬
리뷰 요청	후기/리뷰/사용평 표현이면 리뷰 BM25·dense 추가
최종 수	top_k 기본 10, 허용 1~20
근거	상품당 최대 3청크. 원문·source_id·offset·source_metadata
최소 관련성 점수	현재 min_rrf_score=null
가격·재고	**현재 Python BGE 경로에 Commerce 옵션 가격/재고 하드 필터 없음**
상품 유형·어휘 우선	추천 품질 브랜치의 유형 게이트·어휘 정렬은 현재 BGE 소스에 미통합
필수 조건	가격 범위·임의 필수/선호를 unverified_conditions로 반환
리뷰 선별	추천 품질 브랜치의 REAL 우선·리뷰 중복 제거·짧은 조각 제외는 자동 통합된 것이 아님

BGE 전환은 확인됐지만 **가격 검증 → 용도에 가까운 리뷰 → 필수 옵션 미달 제외**의 전체 흐름은 별도 통합 과제다. 가격 필드가 스키마에 있다는 것만으로 필터가 적용됐다고 표시하지 않는다.

5. LangChain 적용 위치

구성	현재 BGE 실행 경로
BGE 임베딩	자체 BgeM3Embedder → FlagEmbedding. **FastEmbedEmbeddings 경유 아님**
HybridRagRetriever(BaseRetriever)	소스에 존재, Document 변환용 어댑터
HTTP 검색	hybrid_search 직접 호출, Retriever.invoke 경유 아님
MiniLM 복구 경로	LangChain Community FastEmbed 사용 가능
10/18 HTTP 연결 브랜치	search(request) → invoke 구현·검증이 별도로 보존됨
대화/LLM	별도 계층. Python 서비스 전체가 LangChain Agent인 것은 아님

새 구성도에서 BGE 계산을 LangChain FastEmbed로 표시하지 않는다. 과거 LangChain 구성도는 당시 브랜치 자료다.

6. 연동·품질 제한

- 전체 114,106벡터와 */ready를 읽기 전용으로 확인했다.
- 이전 전환 보고서의 네 범주/전체 검색과 복구 smoke는 연결 검사이며 정확도 평가가 아니다.
- 최신 BGE API는 **0.2.0**, 이전 추천 품질 API는 **0.3.0**이다. profile/product_type/filters.in_stock 같은 필드 호환을 맞춰야 한다.
- DB index_profiles는 존재하지만 현재 HTTP는 profile 요청 선택을 지원하지 않는다. 새 active run이 들어오면 최신 run 선택 기준으로 대상이 바뀔 수 있다.

자료: BGE 운영 기록, 전체 적재·전환 보고서, API·Agent 연동.

데이터셋과 저장 구조

목차 · BGE 운영 상태 기준: 2026-10-20 18:25 KST

1. 현재 기본 데이터: test_items2

항목	값
입력 자료	shopping_brain_v6_1_review_refined_CANDIDATE.zip
원본 버전	v6.1-review-refined
입력 ZIP SHA-256	94681a28271ca9b1a6039c98bef10d23cd87beb33004555b9a74d0ca93ccfd8e
상품 / 옵션 / 리뷰	**1,500 / 1,917 / 46,100**
리뷰 출처 구분	REAL 41,523 / SYNTHETIC 4,577
원본 DB	5432 → toss → test_items2
검색 DB	5432 → toss_rag → rag
프로필 / run	test_items2 / e925490f-4f34-4c03-9248-eb9ebdfcde48
전체 청크	**114,106**: 상품·옵션 37,919 / 리뷰 76,187
현재 검색 벡터	**BGE-M3 1,024차원**, 별도 테이블에 114,106개
기존 벡터	MiniLM 384차원 114,106개, 복구용 보존

dataset_version:

```
test_items2:v6.1-review-refined:sha256=94681a28271ca9b1:products=1500:reviews=46100
```

상품/옵션/리뷰 수와 REAL/SYNTHETIC 수는 앞선 원본 DB 조회와 적재 기록의 값이다. 최신 조회에서는 BGE 벡터·프로필·현재 run을 다시 확인했다. 이 데이터는 내부 개발용 **CANDIDATE**다. REAL 표시는 제공자가 부여한 실수집 출처 구분이며, 실제 구매·상품 효능·옵션 연결의 정확성을 독립적으로 검수했다는 뜻은 아니다. 합성 리뷰를 실제 구매 후기처럼 표시하면 안 된다. 가격도 현시점 외부 판매가로 보장하지 않는다.

근거: 원본 데이터 README, 적재 보고서, 색인 보고서, 현재 실행 증거.

2. 카테고리별 범위

카테고리	상품	리뷰	상품 청크	리뷰 청크	전체 청크
beauty	781	34,545	19,485	59,110	78,595
fashion	269	2,761	8,128	3,438	11,566
food	182	5,682	4,364	9,045	13,409
living	268	3,112	5,942	4,594	10,536
합계	**1,500**	**46,100**	**37,919**	**76,187**	**114,106**

"다양한 카테고리를 지원하는 구조"와 "모든 종류의 상품이 현재 들어 있음"은 구분해야 한다. 현재 선택된 run이 지원하는 범주는 위 네 가지다. 새 상품은 원본 적재만으로 검색되지 않으며 색인과 프로필 반영이 필요하다.

3. 원본과 검색 저장소의 관계

현재 BGE API는 검색 DB를 조회한다. 원본 toss.test_items2의 옵션 가격·재고를 실시간 검증하는 Commerce 연결은 현재 BGE 코드에 포함되어 있지 않다. DB의 프로필 포인터와 HTTP의 프로필 선택 지원도 구분한다. 현재 API는 최신 active run을 선택하며 profile 요청 필드는 받지 않는다.

흐름도는 첫 장의 BGE 파이프라인과 동봉 Markdown의 Mermaid 원본을 함께 참고한다.

두 DB 사이 연결은 서비스/ETL에서 ID와 출처 메타데이터로 관리한다. 일반 PostgreSQL 연결에서 서로 다른 DB 테이블을 바로 JOIN하거나 DB 간 외래키가 있다고 가정하지 않는다.

원본 테이블

테이블	핵심 필드	의미
test_items2.products	id, name, brand, category, description, image_urls, specs_json, active, version	상품 정체성과 설명. 이미지는 URL 배열이며 이미지 파일/이미지 임베딩이 아님
test_items2.product_variants	id, product_id, option_values_json, spec_overrides_json, unit_price_won, stock_qty, active, version	**가격·재고는 옵션 단위.** 상품당 여러 옵션 가능
test_items2.reviews	id, product_id, variant_id, rating, body, source_kind, source_ref, written_at, source_option_label	평점 1~5, REAL/SYNTHETIC, 본문 및 원본 옵션 표기 보존

reviews.variant_id는 NULL 가능하다. 값이 있을 때 (product_id, variant_id)가 같은 상품의 옵션을 참조하도록 복합 FK가 있다. source_option_label은 원문 라벨이며 검증된 옵션 ID와 동일한 의미가 아니다.

입력 JSON의 specs, option_values, spec_overrides는 각각 DB의 specs_json, option_values_json, spec_overrides_json으로 매핑한다. 원본 DDL.

검색 테이블

테이블	역할
rag.index_profiles	profile_name → active_run_id 포인터
rag.index_runs	데이터 버전·임베딩 모델·청커·상태·수량. 프로필별 활성 run 관리
rag.indexed_products	색인용 정규화 상품 스냅샷. 원본 상품 DB를 대체하는 테이블이 아님
rag.evidence_chunks	evidence_text, embedding_text, vector(384), 원본 위치와 메타데이터
rag.quarantined_products	분류 문제 등으로 검색에서 격리한 상품과 사유
rag.index_run_embedding_profiles	**현재 BGE 모델의 run별 준비 상태·차원·전체 범위(*)**
rag.evidence_chunk_embeddings	**실제 검색에 사용하는 BGE vector(1024) 114,106개**

기존 DB의 RAG DDL 스냅샷과 BGE 추가 DDL은 작성 시점이 다르다. 전자는 BGE 테이블을 포함하지 않는다. 이 자료들은 구조 설명이며 실행할 마이그레이션 명령으로 취급하지 않는다.

청크에서 원본으로 돌아가는 방법

- product_id → 원본 products.id.
- 리뷰 청크의 source_id → 원본 reviews.id.
- source_type, source_field(JSON Pointer), start_offset, end_offset, source_metadata → 색인에 사용한 문서의 해당 구간.
- run_id와 dataset_version → 어느 데이터·청커·모델로 만들어졌는지.

오프셋은 **색인 입력으로 정규화된 필드**를 기준으로 한다. 원본 DB 필드명과 JSON Pointer가 항상 같은 것은 아니다. 화면에는 반환된 evidence_text를 인용하고, 원본 재대조 때 정규화·마스킹 규칙도 맞춘다.

4. 과거 데이터와 현재의 구분

자료	규모	현재 해석
Amazon Reviews'23 선별 원본	3만 상품 / 178,335리뷰, 가전·의류·식료품 각각 1만 상품	초기 원본 수집·마이그레이션 자료
그중 Appliances 색인	1만 상품 / 65,618리뷰 / 287,105청크	10/15 과거 실험. 현재 test_items2 품질 수치와 합산 불가
test_earphones	과거 인수인계 기록: 50상품 / 50옵션 / 1,000리뷰	이어폰 연동 실험 원본. 현재 기본 프로필 아님
test_items	180상품 / 180옵션 / 4,737리뷰 / 6,741청크	DB의 기존 all_products 프로필. beauty만 있고 리뷰·가격·재고·옵션은 모의 데이터
test_items2	1,500상품 / 1,917옵션 / 46,100리뷰 / 114,106청크	**현재 BGE API가 선택한 run의 데이터**

과거 수량의 출처: 초기 Amazon README, 인수인계서, test_items 내보내기 설명. 과거 이어폰 수량·가전 데이터의 현재 잔존 수량을 이번에 전수 재조회한 것은 아니다.

5. 파일 형태의 자료

기존 내보내기 ZIP은 MiniLM 시점 스냅샷이다. DB에 추가한 최신 BGE 벡터를 포함한 ZIP으로 간주하지 않는다. 이번 전체 자료 ZIP은 문서·모델/배포 기록·실행 소스 사본을 묶은 자료이며 새 BGE 원시 벡터 덤프가 아니다.

자료	기존 위치
test_items2 입력 README·보고서	/home/aiteam/projects/toss-ads-project/data/test_items2/
입력 상품/옵션/리뷰 JSON	위 경로의 source/shopping_brain_v6_1_common_dataset/data/
test_items2 원본+전체 청크+전체 벡터 ZIP	/home/aiteam/projects/toss-ads-project/data/exports/test_items2_chunked_full_2026-10-19.zip
test_items 원본+DB 내보내기 ZIP	/home/aiteam/projects/toss-ads-project/data/exports/test_items_complete_2026-10-18.zip

test_items2 ZIP은 273,558,559바이트이며 청크의 **전체 384차원 숫자 벡터**를 포함한다. 이번 문서 묶음에는 대용량 원본·벡터 덤프를 중복 복사하지 않았고 README·manifest·체크섬과 위치를 수록했다. 전체 위치/파일 목록, 내보내기 읽는 법.

6. 새 상품을 넣을 때 필요한 운영 연결

현재 BGE profile의 scope=*와 114,106벡터가 ready다. 새 데이터가 추가되면 대응 BGE 벡터의 누락 여부와 새 run의 모델 프로필 준비 상태를 확인해야 한다. 이전 index_runs.embedding_model이 MiniLM으로 남는 것은 최초 생성 이력이며, 실제 서비스 모델은 별도 BGE 프로필과 실행 설정으로 판단한다.

1. 상품·옵션·리뷰의 ID, 유형, 옵션 가격·재고, 출처를 원본 DB에 적재한다.

2. 공통 정규화·청킹·임베딩으로 **새 run**을 생성하고 수량·출처·오프셋을 검사한다.

3. 동일 모델/차원의 완성된 임베딩을 확인한 뒤 프로필 포인터와 API 허용 범위를 일치시킨다.

4. Brain/Commerce가 같은 상품·옵션 ID를 사용하도록 연결한다.

5. 새 상품군의 사람 검수 질문과 OOD/가격/필수 옵션 사례로 평가한다.

초기 test_items2 적재는 별도 worker로 수행된 기록이 있다. 임시 worker의 재실행을 일반 운영 CLI로 보장하지 않으며, 영구적인 증분 적재·재색인 진입점 정리는 후속 과제다. 상품마다 개별 검색 코드를 작성하는 방식으로 확장하지 않는다.

청킹과 임베딩 — BGE-M3 기준

목차 · 기준: 2026-10-20 18:25 KST

1. 현재 설정

항목	값
실제 모델	**BAAI/bge-m3**
revision	5617a9f61b028005a4858fdac845db406aefb181
출력	dense **1,024차원**
호출	자체 BgeM3Embedder → FlagEmbedding BGEM3FlagModel
실행	CPU, use_fp16=False
입력 최대 길이	**128토큰**
저장 청크	기존 **v2 / 최대 96토큰 / overlap 없음**
BGE 벡터	**114,106개**, 네 카테고리 전체
MiniLM	기존 384차원 114,106벡터 보존
sparse / ColBERT	사용 안 함

BGE 적용은 **기존 embedding_text를 재사용한 재임베딩**이다. 원본 재수집·재청킹·청크 경계 변경을 수행한 전환은 아니다.

2. 청킹 대상

대상	내용	별도 메타데이터
상품	정규화 문서의 title, features, description, details	상품 ID·분류·버전·원본 연결
옵션	색인 입력에 포함된 옵션명·설명·스펙	variant ID·가격·재고·출처
리뷰	정규화 text 본문, 없으면 title	리뷰 ID·평점·날짜·REAL/SYNTHETIC·옵션 연결

DB의 name/body/specs_json 등을 검색 문서 형태로 옮기는 단계와 청커를 구분한다. 이미지 URL은 메타데이터이며 이미지 임베딩 대상이 아니다.

흐름도는 첫 장의 BGE 파이프라인과 동봉 Markdown의 Mermaid 원본을 함께 참고한다.

3. 분할과 원문 추적

- 문장·줄바꿈·공백 경계를 우선하고 토큰 예산에 맞게 분할한다.
- 상품명·필드명 접두어도 96토큰 예산에 포함한다. 본문 96토큰에 접두어를 추가하는 방식이 아니다.
- evidence_text는 원문 구간, embedding_text는 문맥과 원문 구간이다.
- offset과 JSON Pointer를 보존한다. 청커가 요약·의역한 문장을 원문 근거로 저장하지 않는다.
- 청크 ID에는 데이터·상품·출처·필드·offset·청커/모델 등의 해시 재료가 들어간다.
- 이번 BGE 테이블은 기존 run/chunk_id를 참조한다. 청크 ID 전체를 새 모델명으로 다시 생성한 방식이 아니다.

실행 소스: 청커, BGE 어댑터, 임베더 선택.

4. BGE인데도 96토큰인 이유

96은 초기 MiniLM 색인에서 사용한 크기다. BGE 비교·전환에서는 모델 차이만 보고 기존 청크·출처를 재사용하기 위해 경계를 유지했다. 현재 BGE 호출 상한도 128토큰이다.

BGE로 바꿨다고 청크가 자동으로 길어지지는 않는다. 96이 최적이라는 길이 비교 실험은 발견하지 못했다. 모델의 지원 최대 길이와 현재 설정 길이를 구분해야 한다.

길이를 조정하려면 동일한 사람 검수 질의/정답에서 길이별 새 run을 만들고 재임베딩한다. 적중률·근거 완결성·지연·비용을 함께 비교한다. 다른 토크나이저에서 같은 embedding_text가 몇 토큰이 되는지도 별도 확인해야 한다. 이번 자료 갱신에서 입력 잘림이나 길이별 품질을 새로 측정하지 않았다.

5. v3의 상태

추천 품질 브랜치에는 관리용 필드 제외와 짧은 리뷰 꼬리 조각 병합/경계 재배분을 포함한 v3가 있다. **현재 BGE 실행 코드와 활성 청크는 v2**다.

구분	상태
v2 기존 청크	현재 사용
v3 청커	별도 추천 품질 브랜치에 보존
v3 전체 재청킹·재임베딩	이번 BGE 전환에 미포함
REAL 우선·짧은 조각 제외	별도 추천 품질 기능, BGE 실행본에 자동 통합된 것은 아님

v3 적용은 새 청킹·BGE 임베딩 범위를 함께 갱신하고 검증하는 작업이다. 코드 파일만 바꿔 저장된 v2가 바뀐 것으로 표시하지 않는다.

6. 모델별 위치

모델	차원	상태
BGE-M3	**1,024**	**현재 API 모델, 전체 벡터 준비**
MiniLM-L12-v2	384	기존 기준선·복구용
multilingual-e5-large	1,024	두 beauty 데이터 오프라인 비교
Qwen3-Embedding-0.6B	1,024	두 beauty 데이터 오프라인 비교
multilingual-mpnet-base-v2	768	후보 언급, 실측 없음
bge-reranker-v2-m3	별도 역할	리랭커 후보, 적용/측정 없음

최종 답변 LLM은 임베딩 모델과 별도다. BGE는 문서·질문을 벡터로 바꾸며 추천 문장을 생성하지 않는다.

7. LangChain

BGE의 embed_query/embed_documents라는 이름이 LangChain 상속이나 FastEmbed 경유를 뜻하지 않는다. 실제 계산은 FlagEmbedding이다. LangChain Retriever 어댑터는 존재하지만 HTTP는 검색 함수를 직접 호출한다.

준비 상태는 실행 증거, 품질/비용은 모델 비교를 참조한다.

모델 비교와 RAG 평가 기록 — BGE 운영 기준

목차 · 원문 전체 목록

현재 운영 모델은 BGE-M3이며 전체 114,106개 벡터가 ready다(2026-10-20 18:25 KST 확인). 아래의 MiniLM/E5/Qwen 결과는 비교 기준선과 과거 실험 기록이다. 운영 전환 완료와 전체 추천 정확도 평가 완료는 구분한다.

1. 결과를 읽는 기준

발견한 자료에는 **임베딩 모델 비교 2묶음, BGE-M3 DB 검색 비교 1묶음**, 그리고 여러 시점의 검색·정책·출처 검사가 있다. 데이터, 질문, 라벨, 코드, 검색 경로가 달라 점수를 한 개의 "현재 정확도"로 합칠 수 없다.

- 대부분 상품명/유형 규칙으로 만든 **임시 정답**이며 사람 검수 gold가 없다.
- 임베딩 비교는 긍정 질문 10개와 OOD(목록/범위 밖) 2개다. 긍정 질문 하나가 Hit 비율 10%p를 바꾼다.
- Hit@5는 관련 상품이 다섯 개 안에 하나 있다는 뜻이며, 가격·용도·필수 옵션을 모두 충족했다는 뜻은 아니다.
- 출처/오프셋 무결성과 사용자 요구에 맞는 추천은 다른 평가 항목이다.
- 아래 표는 **저장된 결과를 정리한 것**이다. 이번 문서 작업에서 모델 평가를 새로 실행하지 않았다.

2. 비교 A — test_items/beauty, 2026-10-19

상품 180개 / 리뷰 4,737개 / 기존 96토큰 청크 6,741개. 긍정 10 + OOD 2, 결과 Top 5. 저장한 BM25 Top 20과 모델별 dense Top 20을 상품 단위 RRF(k=60)로 합쳤다.

구성	차원	Hit@1	Hit@5	Recall@5	MRR@5	Precision@5	OOD 반환
BM25	—	70%	80%	.533	.750	.340	2/2
BM25 + MiniLM	384	70%	80%	.503	.750	.360	2/2
BM25 + multilingual-e5-large	1,024	**80%**	**90%**	.583	**.850**	**.440**	2/2
BM25 + BGE-M3 dense	1,024	70%	**90%**	**.598**	.800	.420	2/2
BM25 + Qwen3-Embedding-0.6B	1,024	70%	**90%**	.536	.800	.420	2/2

표의 Recall/MRR/Precision은 질문별 값을 평균한 macro 지표다. 이 표본에서는 E5의 상위 순위가 좋고 BGE-M3의 Recall이 가장 높았지만, 최종 모델의 우열을 확정한 결과는 아니다.

원문: test_items 임베딩 비교.

로컬 CPU 비용

모델	6,741청크 문서 임베딩	청크/초	질문 임베딩 p50 / p95
MiniLM	33.8초	199.6	5.7 / 10.2ms
E5-large	456.3초	14.8	55.6 / 67.4ms
BGE-M3	879.6초	7.7	145.6 / 167.9ms
Qwen3-Embedding-0.6B	894.6초	7.5	92.8 / 154.5ms

문서 임베딩 시간은 모델 시작·DB 저장·DB 인덱스 생성을 제외한다. MiniLM/E5/Qwen은 ONNX FastEmbed, BGE는 Transformers CPU bfloat16 경로다. Dense 검색은 NumPy 메모리 행렬이므로 서비스 API 지연으로 읽지 않는다.

3. 비교 B — test_items2/beauty, 2026-10-19

상품 781개 / 리뷰 34,545개 / 기존 96토큰 청크 78,595개. 전체 test_items2 1,500상품 중 beauty만 평가했다. 긍정 10 + OOD 2, 상품 Top 5, BM25/dense Top 20, RRF(k=60).

구성	차원	Hit@1	Hit@5	Recall@5	MRR@5	Precision@5	OOD 반환
BM25	—	60%	100%	.540	.767	.400	2/2
BM25 + MiniLM	384	40%	100%	.451	.595	.360	2/2
BM25 + E5-large	1,024	**80%**	100%	.620	.883	**.580**	2/2
BM25 + BGE-M3 dense	1,024	**80%**	100%	**.627**	**.900**	**.580**	2/2
BM25 + Qwen3-Embedding-0.6B	1,024	**80%**	100%	.608	.883	**.580**	2/2

E5/BGE/Qwen이 이 표본에서 MiniLM보다 상위 순위가 좋았지만 모든 구성에서 OOD 두 건에도 상품을 반환했다. 큰 임베딩 모델만으로 무관한 상품 차단을 해결한 결과는 아니다.

원문: Markdown, 공유 PDF.

로컬 CPU 비용

모델	78,595청크 문서 임베딩	청크/초	질문 임베딩 p50 / p95
MiniLM	기존 DB 벡터 재사용	미측정	4.2 / 12.4ms
E5-large	90.3분	14.50	21.6 / 27.2ms
BGE-M3	48.9분	26.81	135.2 / 143.9ms
Qwen3-Embedding-0.6B	173.2분	7.56	53.0 / 58.9ms

CPU 8 threads, 모델별 실행 경로 차이가 있다. 문서 시간은 DB 적재를 제외하며 dense는 NumPy exact cosine이다. 비교 A와 다른 실행 시점/환경의 측정치를 합쳐 고정 처리량이나 운영 SLA로 사용하지 않는다.

두 비교의 공통 통제 조건

- 청크는 기존 96토큰으로 고정했다. **청크 길이 비교 실험이 아니다.**
- 모든 모델 호출의 최대 입력은 128토큰이었다. 모델의 전체 장문 처리 능력을 평가한 것이 아니다.
- E5는 문서 passage:, 질문 query:를 사용했다. Qwen 질문은 검색 지시문 템플릿을 사용했다.
- BGE는 dense만 사용했다. sparse/ColBERT, cross-encoder 리랭커, 답변 생성 LLM은 포함하지 않았다.
- 비교 A와 B는 일부 긍정 질문·OOD·정답 목록도 다르다. 이전 데이터 대비 개선율로 해석하지 않는다.
- 10/19 문서의 "test_items2가 API에 미연결" 문구는 작성 당시 상태다. 현재 API 기본 연결은 현재 구성을 따른다.

4. 비교 C — BGE-M3 DB 검색, 2026-10-20

같은 test_items2/beauty 78,595청크에 별도 BGE 1,024차원 벡터를 저장한 후, **BM25 / BM25+BGE / BGE 단독**을 DB 경로에서 비교했다. 긍정 10 + OOD 2, Top 5, RRF(k=60). 모델 revision은 5617a9f61b028005a4858fdac845db406aefb181, 최대 입력 128토큰이다.

지표	BM25	BM25+BGE	BGE dense
Hit@1	60%	**80%**	**80%**
Hit@5	**100%**	**100%**	90%
Macro Recall@5	.5403	**.6064**	.4694

지표	BM25	BM25+BGE	BGE dense
Macro MRR@5	.7667	**.8833**	.8333
Macro Precision@5	.4000	**.5400**	.5000
OOD 결과 반환	2/2	2/2	2/2

시간 측정	BM25	BM25+BGE	BGE dense
질문 임베딩 p50 / p95	—	70.544 / 122.615ms	71.472 / 102.733ms
검색 p50 / p95	54.520 / 67.430ms	81.858 / 3,266.474ms	702.144 / 772.439ms

검색 시간은 질문 임베딩을 제외한다. 12번 단발 측정이므로 특히 p95는 재측정이 필요하다. 하이브리드 p95 약 3.27초가 기록됐다. 부하·워밍업·반복을 통제한 운영 지연 수치는 아니다.

벡터 적재의 마지막 재개 구간은 75,235청크 임베딩에 약 2시간 58분 41초, 전체 경과 약 3시간 8분 59초였다. 기존 3,360벡터와 앞선 중단 실행 시간은 이 구간 비용에 포함되지 않는다. 이 비용을 10/19 NumPy 실험 시간과 같은 조건의 측정으로 비교하지 않는다.

평가 중 BM25 준비 쿼리의 Unsupported query shape 오류를 발견하고 prepare=False로 회귀 확인한 기록도 있다. 해당 수정의 기록과 현재 배포 반영 여부는 구분한다. 이 문서 작업에서 운영 코드를 바꾸지 않았다.

원문: Markdown, PDF, 전체 질의/응답 JSON, 적재 결과, 고정 질문/정답 fixture.

5. 전체 BGE 적재·운영 전환 기록

전체 test_items2의 **1,500상품 / 46,100리뷰 / 114,106청크**에 BGE 벡터를 준비했다. 기존 beauty 78,595개를 재사용하고 fashion/food/living **35,511개**를 추가했다. 재청킹하지 않았고 기존 MiniLM 벡터도 보존했다.

항목	기록
BGE 벡터 전체	114,106개
beauty / fashion / food / living	78,595 / 11,566 / 13,409 / 10,536
모델·차원	BAAI/bge-m3, 1,024
프로필	scope=*, ready
추가 35,511개 순수 임베딩	8,473.861초, 약 2시간 21분 14초
추가 구간 경과	8,954.353초, 약 2시간 29분 14초
순수 처리량	4.191청크/초
해당 작업 CPU threads / 최대 RSS	20 / 2,541.86MB
카테고리 4개 + 전체 검색 smoke	기록상 5/5 HTTP 200, 각각 5상품
MiniLM 복구 후 BGE 복원 smoke	기록상 passed

위 시간은 **추가분의 비용**이며 전체 114,106개를 처음부터 임베딩한 총시간이 아니다. 이전 중단 실행까지의 총비용도 아니다. 현재 실행 상태와 BGE 범주별 실제 벡터 수는 별도 읽기 전용 조회로 다시 확인했다.

원문: 전체 적재·전환 보고서, 운영 기록, 새 실행 증거.

전체 카테고리의 정확도·Recall·최종 추천 품질은 새로 측정된 수치가 없다. Fashion/food/living의 사람 승인 라벨이 없으며 연결 smoke를 정확도로 바꾸지 않는다. Beauty의 80% Hit@1을 전체 1,500상품의 80% 정확도로 표기하지 않는다.

6. 그 밖의 평가를 시간순으로 읽기

자료/시점	대상·주요 결과	해석
10/15 Amazon Appliances	1만 상품, 65,618리뷰, 287,105청크. 관련성 8사례 중 상품 적중 7, 정확한 source 적중 4, 전체 통과 4	과거 가전 실험. 팀 의미 라벨 승인 대기, holdout 독립성 제한. 현재 정확도 아님
10/17 test_items API 초기/재실행	긍정 10 + OOD 2. Hit@1 60%, Hit@5 80%. OOD 2/2 반환. 근거 118건 일치	당시 all_products/beauty 검색 경로와 출처 검사
10/17 test_items 검색 품질 문서	같은 규모 긍정 10개에서 Hit@1 70%, Hit@5 80%, MRR .750, 근거 116건 일치	인덱스 재작성 후 순위 변동과 재현 기록. 이전 결과와 평균 내지 않음
10/17 개선 진단	RRF k=10/가중치, 요청 표현 제거, 일부 별칭 확장 재생 비교	일부 질의에 직접 준 별칭으로 90%/100%가 나왔지만 전체 카테고리 일반 성능 아님
10/17 리뷰 추천 정책	5개 질의 smoke, 근거 16개 일치, 키보드/클렌징오일 제외, 모의 가격이면 예산 추천 보류	격리 브랜치의 정책 확인. 당시 운영 API 배포 결과 아님
10/18 LangChain HTTP 연결	요청 조건 보존·요청 격리·상태/오류·HTTP 경유 검증 기록	연결 동작 검사. 추천 정확도 평가 아님
10/19 test_items2 전체 범주 탐색	자연어 24 + 상품명 8 + 후기 대조 4 + OOD 4 + 예산 2 + 미지원 범주 1 = 43건	직접 hybrid_search 호출. 현재 배포본의 HTTP E2E 평가 아님

test_items2 전체 범주 탐색 수치

지표	당시 결과
자연어 Hit@1 / Hit@5	58.3% (14/24) / 91.7% (22/24)
Precision@5 / MRR@5 / nDCG@5	.558 / .750 / .629
Macro Recall@5	.375
상품명 그대로 검색	8/8 1위
반환 근거 무결성	447건 중 ID·원문·출처·offset 불일치 0
OOD	4/4 무관 상품 반환
예산	당시 별도 Commerce 검증 전 경로에서 초과 상품 반환

후속 추천 품질 브랜치 24a1051에는 상품 관련성·옵션 가격/재고·근거 선별 개선이 있다. 현재 BGE 실행본은 그 기능 전체를 통합한 배포가 아니다. 따라서 과거 MiniLM 점수에 구현 효과를 더해 BGE 성능을 계산하거나, 해당 개선이 현재 모두 동작한다고 표시하지 않는다.

관련 원문:

- test_items 품질 재평가
- 초기 API 평가
- API 재실행 평가
- 개선 진단
- 리뷰 정책 검사
- test_items2 43건 평가 요약
- test_items2 질문/정답
- test_items2 전체 상세 결과

10/15 평가 manifest·tuning·holdout·출처 검사와 LangChain 검증 JSON은 전체 평가 목록에서 찾을 수 있다.

7. 측정하지 않은 항목과 다음 비교의 기준

항목	확인된 공백
사람 검수 정답	상품·용도·근거를 사람이 판정한 충분한 gold/독립 holdout 부재
청크 길이	96 대비 다른 길이의 통제 실험 부재
범주 일반화	임베딩 모델 비교는 beauty. fashion/food/living 모델 우열은 미확인
OOD 거절	모델 비교 경로에서 모두 상품 반환. 별도 유형/거절 정책 평가 필요
필수 옵션	임의 필수 문장의 사실 검증을 포괄하지 않음
리뷰 설명 품질	출처 무결성은 검사했으나 용도 적합성·반대 근거·최종 설명의 충실성은 별도 평가 필요
API/Brain/웹	현재 배포본에서 가격·재고·상품명 순위가 최종 카드까지 유지되는 E2E 평가 필요
지연	HTTP·DB·임베딩·LLM을 나눈 반복/동시 부하 p95 필요

모델 후보로는 기존 실험에서 E5와 BGE를 계속 비교할 근거가 있다. 운영 채택에는 같은 최신 데이터·사람 라벨·동일 검색 정책·거절 기준·비용 조건이 필요하다. MPNet과 BGE 리랭커는 후보 언급만 있고 실제 결과표는 발견하지 못했다.

BGE API·Agent 연동과 남은 과제

목차 · 현재 BGE 구성 · 확인: 2026-10-20 18:25 KST

1. 연결과 역할

이름	역할
search_rag	AI 추천용 RAG 검색 도구. 실제 서버·데이터·계약을 어댑터에서 맞춰야 함
search_products / searchProducts	Commerce의 일반 상품 목록·카탈로그 탐색. 이름만으로 임베딩 검색을 보장하지 않음
POST /v1/rag/search	현재 BGE Python 검색 API
Brain / 최종 LLM	예산·용도·상품 종류 확인, 미검증 조건 처리, 설명/카드 생성

현재 Python API는 **BM25 + BGE-M3 dense 검색**을 제공한다. 도구 이름이 search_rag여도 Brain이 local RAG나 다른 서버로 연결하면 이 BGE 실행본을 사용하는 것이 아니다. 브라우저부터의 E2E는 이번 자료 갱신에서 재실행하지 않았다.

2. 현재 계약은 API 0.2.0

이전 추천 품질 API의 0.3.0 문서와 최신 BGE 실행본을 구분해야 한다. 현재 모델 설정과 OpenAPI를 직접 읽었으며, 실제 요청 스키마도 JSON으로 저장했다.

요청 항목	현재 지원
original_question, query	필수 문자열
request_id	선택 추적 ID
category	선택. 생략하면 현재 run의 전체 범주
filters.price_min, price_max, currency	형식 검증 지원. **가격 하드 필터 적용은 아님**
required_conditions, preferences	배열. 현재는 미검증 조건으로 반환
top_k	기본 10, 1~20
profile	현재 요청 스키마에 없음
product_type	현재 요청 스키마에 없음
filters.in_stock	현재 요청 스키마에 없음

추가 필드 금지 설정이므로 미지원 항목을 포함한 0.3.0 요청은 validation상 422 대상이다. 이 사실은 실행 스키마와 코드에서 확인했으며, 이번 문서 작업 중 오류 POST를 새로 보낸 테스트 결과는 아니다.

사용 예시

아래 예시는 현재 지원 형식이며 실제 검색 성공이나 모든 조건 충족을 입증하는 결과가 아니다.

```
POST /v1/rag/search
Content-Type: application/json
```

```
{
"request_id": "bge-doc-example-001",
"original_question": "통학용으로 5만원 이하 백팩을 찾아줘. 후기도 궁금해",
"query": "통학용 백팩 후기",
"category": "fashion",
"filters": {"price_max": 50000, "currency": "KRW"},
"required_conditions": [],
"preferences": ["통학용"],
```

```
  "top_k": 5
}
```

위 price_max는 현재 BGE 엔진에서 적용되지 않고 미검증으로 돌아온다. 소비 측이 이를 예산을 충족한 추천으로 표시해서는 안 된다.

3. 응답 처리

항목	의미·처리
HTTP 상태, status, error_code	오류·미준비·결과 없음 구분
dataset_version, supported_categories	실제 데이터 범위 확인
applied_filters	현재 category 같은 적용 조건 확인
unverified_conditions	가격·필수·선호 중 검증하지 못한 요구
items/evidence	상품 ID·원문 청크·리뷰 ID·출처·offset
rrf_score	채널 순위 결합 점수. 확률/조건 충족률 아님

이전 0.3.0의 profile_name, search_context, items.commerce, items.ranking 필드가 현재 BGE 응답에 있다고 가정하지 않는다. 현재 OpenAPI 경로는 /healthz와 /v1/rag/search이며, 이전 /v1/catalog/test-items 목록·리뷰 경로도 현재 이미지에 자동 유지된 것으로 보지 않는다.

DB에는 test_items2/all_products 프로필 정보가 남아 있지만 현재 서비스의 active_run은 최신 active 실행을 고른다. 요청에서 profile=all_products를 보내 기존 색인으로 바꾸는 계약이 아니다.

4. 모델 전환과 함께 달라진 기능 범위

기능	이전 추천 품질 브랜치	현재 BGE 실행본
임베딩	MiniLM 384	**BGE 1,024**, 전체 준비
요청 계약	0.3.0 확장	**0.2.0**
프로필 요청 선택	지원	미지원, 최신 active 선택
상품 유형/동의어 게이트	구현	현재 소스에 미통합
같은 옵션 가격·재고 검증	CommerceStore 구현	현재 경로에 미통합
후보 확장	최대 50개 서로 다른 상품 목표	채널별 20청크
정렬	상품명/정체성 어휘 → RRF	RRF → 안정 ID
리뷰 선별	REAL 우선·중복/짧은 근거 제외	해당 개선 미통합
LangChain HTTP invoke	별도 연결 브랜치에 구현	직접 hybrid_search 호출

BGE 모델 전환만으로 이전 브랜치의 모든 기능이 합쳐진 것은 아니다. 자료에는 모델 적용 완료와 추천 정책 통합 과제를 따로 표시했다.

5. 원하는 추천 동작과 통합 과제

1. 대화에서 상품 종류·예산·용도를 확인한다. 사용자가 제거 요청한 강제 사전 입력 폼을 과거 intake 설계 문서만 보고 재도입하지 않는다.

2. 같은 옵션의 단가·재고·필수 스펙으로 적격 후보를 먼저 정한다. 배송비 포함 총액은 별도 계산한다.

3. 적격 후보의 리뷰를 BM25/BGE로 회수하고 용도와 가까운 원문 근거를 연결한다.

4. 필수 옵션 불일치나 미확인 시 조건 충족 추천으로 표시하지 않는다. 사용자가 조건을 제시하지 않았으면 그 필터를 적용하지 않는 경우와 구분한다.

5. 조회 실패·부분 도구 실패·미검증 필수 조건이 있으면 Brain/UI가 추천 카드를 보류하도록 연동한다.

6. 상품명/상품군·OOD·예산·옵션·리뷰 provenance와 최종 화면 순위까지 평가한다.

현재 BGE API는 3번의 검색 기반을 제공한다. 나머지 모든 검증을 완료한 통합 추천 시스템으로 설명하지 않는다.

6. 접속과 운영 자료

- 서버 내부: http://127.0.0.1:8002, 이번 healthz 확인.
- 기존 공유 도메인/터널: 과거 API·운영 문서에 보존. 이번에 외부 접속을 재확인하지 않았다.
- 최신 BGE 운영 기록.
- 전체 벡터·전환·복구 smoke 보고서.
- 이전 0.3.0 API 가이드는 과거 계약의 참고 자료다.

복구 컨테이너와 예전 MiniLM 벡터는 기존 운영 보고서에 보존 기록이 있다. 이번 작업은 복구/재전환을 실행하지 않았다.

7. 프롬프트·팀 요구사항 원문

- Agent 기본 지침 v0.6: Mock 단독 실험 초안.
- 유저 스토리.
- 프롬프트 공유 PDF.
- 수정요청서 v1.3: 상품명 우선, 유형 혼동, 실제 경로, 가격/옵션, 평가 요구.

문서 수록이 실제 LLM 프롬프트 적용·유저 스토리 구현 완료를 뜻하지 않는다. Mock의 products/error, 현재 RAG의 items/error_code 등 입력 형식도 맞춰야 한다.

8. 다음 작업 우선순위

1. Brain 어댑터가 현재 BGE API 0.2.0에 맞게 호출하는지 확인.

2. BGE에 추천 품질 브랜치의 가격/재고·유형·후보/근거 정책과 명시적 프로필을 통합.

3. LangChain Retriever 요청/응답 보존 경로를 통합할지 역할을 명확히 정리.

4. 사람이 검수한 전 카테고리 질의/정답/거절 조건으로 BGE 전체를 평가.

5. v3 재청킹·장문 청크 실험·리랭커는 각각 효과를 분리해 측정.

이 목록은 후속 작업이며 이번 문서 갱신에서 코드·배포·DB를 수정한 기록이 아니다.

부록 — 전체 원문 목록

원문 239개, 발견 위치/버전 300건. 전체 출처·원문 파일·해시는 동봉 document-catalog.md와 source-manifest.json에서 확인한다.

01-model-comparisons

ID	원문 제목	형식
RAG-DOC-062	test_items2/beauty 검색 비교: BM25와 BGE-M3	MD
RAG-DOC-063	rag-bge-m3-test-items2-beauty-2026-10-20.pdf	PDF
RAG-DOC-064	test_items/beauty 임베딩 모델 비교	MD
RAG-DOC-065	test_items2/beauty 임베딩 모델 비교	MD
RAG-DOC-066	rag-embedding-model-comparison-test-items2-beauty-2026-10-19.pdf	PDF
RAG-DOC-072	test_items2_beauty_bge_m3.json	JSON
RAG-DOC-073	rag-bge-m3-test-items2-beauty-2026-10-20-index.json	JSON
RAG-DOC-074	rag-bge-m3-test-items2-beauty-2026-10-20.json	JSON

02-evaluations

ID	원문 제목	형식
RAG-DOC-204	search-tuning-appliances-2026-10-15.json	JSON
RAG-DOC-193	amazon_reviews_rag_cases.json	JSON
RAG-DOC-202	search-holdout-appliances-review-channels-2026-10-15.json	JSON
RAG-DOC-203	search-tuning-after-chunk-dedup.json	JSON
RAG-DOC-195	amazon_reviews_rag_sources.json	JSON
RAG-DOC-199	label-review-2026-10-15.json	JSON
RAG-DOC-196	evaluation-manifest-2026-10-15.json	JSON
RAG-DOC-194	amazon_reviews_rag_negative_proposals.json	JSON
RAG-DOC-215	amazon_reviews_rag_cases.json	JSON
RAG-DOC-201	search-holdout-appliances-retry-2026-10-15.json	JSON
RAG-DOC-205	search-tuning-appliances-final-2026-10-15.json	JSON
RAG-DOC-206	search-tuning-first-run.json	JSON
RAG-DOC-200	search-holdout-appliances-final-2026-10-15.json	JSON
RAG-DOC-079	langchain-http-verification-2026-10-18.json	JSON
RAG-DOC-088	catalog-profile-smoke-2026-10-17.json	JSON
RAG-DOC-089	RAG 개선 진단 — 2026-10-17	MD
RAG-DOC-090	rag-performance-evaluation-2026-10-17.json	JSON
RAG-DOC-091	RAG retrieval evaluation — 2026-10-17	MD
RAG-DOC-092	rag-performance-evaluation-rerun-2026-10-17.json	JSON
RAG-DOC-093	RAG 실시간 재평가 — 2026-10-17	MD
RAG-DOC-094	rag-review-policy-evaluation-2026-10-17.json	JSON
RAG-DOC-095	리뷰 기반 추천 정책 재검증 — 2026-10-17	MD
RAG-DOC-152	langchain-http-verification-2026-10-18.json	JSON
RAG-DOC-126	search_quality_2026-10-19.json	JSON

ID	원문 제목	형식
RAG-DOC-127	test_items2 RAG 탐색 평가 — 2026-10-19	MD
RAG-DOC-128	search_quality_cases_2026-10-19.json	JSON
RAG-DOC-132	test_items/beauty 검색 품질 재평가	MD
RAG-DOC-138	rag-search-quality-test-items-beauty-2026-10-17.json	JSON

03-datasets-indexing

ID	원문 제목	형식
RAG-DOC-239	rag-bge-m3-test-items2-full-2026-10-20-index.json	JSON
RAG-DOC-216	test_items2 청킹·임베딩 공유 자료	MD
RAG-DOC-217	65a34cbcf3348d1c65ca626eeeb44fb29320ccecc050582906c786a17a5e059e README_KO.md	TXT
RAG-DOC-218	schema.sql	SQL
RAG-DOC-219	schema.sql	SQL
RAG-DOC-220	export_manifest.json	JSON
RAG-DOC-221	test_items 전체 데이터 묶음	MD
RAG-DOC-222	b0ccd5e498d88fad8da5eb60903d4cb370d1baa779afc9f95e9256425848f697 README_KO.md	TXT
RAG-DOC-223	schema.sql	SQL
RAG-DOC-224	schema.sql	SQL
RAG-DOC-225	export_metadata.json	JSON
RAG-DOC-226	Shopping Brain v4 — 실제 상품 통계 기반 시연용 데이터셋 (검증 범위 명시)	MD
RAG-DOC-227	v4 Commerce / RAG 데이터 계약	MD
RAG-DOC-228	Release Gates (2026-10-16)	MD
RAG-DOC-229	Holdout 정책	MD
RAG-DOC-230	v4 모의 시연용 데이터 QA	MD
RAG-DOC-231	SHA256_MANIFEST.json	JSON
RAG-DOC-198	full-index-2026-10-15.json	JSON
RAG-DOC-208	source-validation-2026-10-15.json	JSON
RAG-DOC-209	source-validation-appliances-2026-10-15.json	JSON
RAG-DOC-207	source-privacy-audit-2026-10-15.json	JSON
RAG-DOC-140	Amazon Reviews'23 선별 데이터	MD
RAG-DOC-141	manifest.json	JSON
RAG-DOC-121	test_items2 데이터 적재 및 색인	MD
RAG-DOC-122	index_report.json	JSON
RAG-DOC-123	load_report.json	JSON
RAG-DOC-124	run.json	JSON
RAG-DOC-125	schema_validation_2026-10-19.json	JSON

ID	원문 제목	형식
RAG-DOC-129	Shopping Brain V6.1 — Review Language Refinement (CANDIDATE)	MD
RAG-DOC-130	zip_export_report.json	JSON
RAG-DOC-012	model-cache-manifest.json	JSON

04-database-operations

ID	원문 제목	형식
RAG-DOC-236	BGE-M3 Full-Dataset Operations	MD
RAG-DOC-008	0. 가장 먼저 알아둘 사항 : PDF 1쪽	TXT
RAG-DOC-009	운영 인수인계 자료	MD
RAG-DOC-010	data-archive-locator.json	JSON
RAG-DOC-011	fastembed-supported-models-runtime.json	JSON
RAG-DOC-013	observed-inventory.json	JSON
RAG-DOC-014	rag-api-tailscale.postman_collection.json	JSON
RAG-DOC-015	PostgreSQL · RAG 운영 인수인계서	MD
RAG-DOC-016	PyYAML==6.0.3	TXT
RAG-DOC-017	01_toss_inventory.sql	SQL
RAG-DOC-018	02_test_items2_catalog.sql	SQL
RAG-DOC-019	03_rag_active_profile.sql	SQL
RAG-DOC-020	04_rag_product_chunks.sql	SQL
RAG-DOC-021	05_toss_linkage_checks.sql	SQL
RAG-DOC-022	06_rag_model_baseline.sql	SQL
RAG-DOC-023	toss.test_items2.schema.sql	SQL
RAG-DOC-024	toss_rag.rag.schema.sql	SQL
RAG-DOC-025	Nginx Proxy Manager → RAG LAN 연결 적용	MD
RAG-DOC-042	rag-db-operations-handover-2026-10-19.pdf	PDF
RAG-DOC-043	rag-db-operations-handover-2026-10-19.zip	ZIP

05-api-contracts

ID	원문 제목	형식
RAG-DOC-174	response-unsupported-category.json	JSON
RAG-DOC-178	RAG 규격·공통 질문과 검증 실행	MD
RAG-DOC-158	response-error.json	JSON
RAG-DOC-171	response-low-relevance.json	JSON
RAG-DOC-211	response-ok.json	JSON
RAG-DOC-159	response-low-relevance.json	JSON
RAG-DOC-167	request-category.json	JSON
RAG-DOC-170	response-error.json	JSON
RAG-DOC-210	Amazon Reviews RAG v0.1 공동 계약	MD
RAG-DOC-164	response.schema.json	JSON
RAG-DOC-165	source.schema.json	JSON
RAG-DOC-212	RAG 규격·공통 질문과 검증 실행	MD
RAG-DOC-166	Amazon Reviews RAG v0.2 카테고리 제한 계약 제안	MD
RAG-DOC-197	examples-validation.json	JSON
RAG-DOC-175	request.schema.json	JSON
RAG-DOC-163	request.schema.json	JSON
RAG-DOC-156	Amazon Reviews RAG v0.1 공동 계약	MD
RAG-DOC-157	request.json	JSON
RAG-DOC-177	source.schema.json	JSON
RAG-DOC-168	request-unsupported-category.json	JSON
RAG-DOC-176	response.schema.json	JSON
RAG-DOC-162	source.json	JSON
RAG-DOC-173	response-ok.json	JSON
RAG-DOC-172	response-no-results.json	JSON
RAG-DOC-169	response-category-ok.json	JSON
RAG-DOC-161	response-ok.json	JSON
RAG-DOC-160	response-no-results.json	JSON
RAG-DOC-002	request.schema.json	JSON
RAG-DOC-004	rag-search.request.json	JSON
RAG-DOC-005	rag-search.response.example.json	JSON
RAG-DOC-006	Product RAG API 연동 문서	MD

ID	원문 제목	형식
RAG-DOC-007	rag-api.postman_collection.json	JSON
RAG-DOC-028	rag-api-docs-2026-10-19.zip	ZIP
RAG-DOC-029	rag-api-guide-2026-10-19.pdf	PDF

06-agent-requirements

ID	원문 제목	형식
RAG-DOC-133	rag-system-prompt-share-2026-10-19.pdf	PDF
RAG-DOC-030	rag-change-requests-2026-10-19-v1.1.json	JSON
RAG-DOC-031	Shopping Brain · RAG 추천 품질 수정요청서	MD
RAG-DOC-032	rag-change-requests-2026-10-19-v1.1.pdf	PDF
RAG-DOC-033	rag-change-requests-2026-10-19-v1.2.json	JSON
RAG-DOC-034	Shopping Brain · RAG 추천 품질 수정요청서	MD
RAG-DOC-035	rag-change-requests-2026-10-19-v1.2.pdf	PDF
RAG-DOC-036	rag-change-requests-2026-10-19-v1.3.json	JSON
RAG-DOC-037	Shopping Brain · RAG 추천 품질 수정요청서	MD
RAG-DOC-038	rag-change-requests-2026-10-19-v1.3.pdf	PDF
RAG-DOC-039	rag-change-requests-2026-10-19.json	JSON
RAG-DOC-040	Shopping Brain · RAG 추천 품질 수정요청서	MD
RAG-DOC-041	rag-change-requests-2026-10-19.pdf	PDF
RAG-DOC-153	Toss Shopping Brain — Agent 기본 지침 v0.6	TXT
RAG-DOC-154	토스 brain 쇼핑 AI 에이전트 유저 스토리	TXT

07-designs-plans-progress

ID	원문 제목	형식
RAG-DOC-080	SDD ledger — plan: docs/superpowers/plans/2026-10-15-rag-service-integration.md	MD
RAG-DOC-232	SDD ledger — plan: docs/superpowers/plans/2026-10-20-rag-bge-m3-full-dataset-activation.md	MD
RAG-DOC-233	Task 4: Document and safely switch the local API runtime	MD
RAG-DOC-234	Task 5: Populate the full profile and activate BGE-M3	MD
RAG-DOC-237	test_items2 Full-Dataset BGE-M3 Activation Implementation Plan	MD
RAG-DOC-238	BGE-M3 dense 검색 전환 및 비교 설계	MD
RAG-DOC-047	SDD ledger — plan: docs/superpowers/plans/2026-10-20-rag-bge-m3-dense-hybrid.md	MD
RAG-DOC-048	Task 1: BGE-M3 dense 임베딩 어댑터	MD
RAG-DOC-049	Task 2: 추가 임베딩 프로필·벡터 저장소	MD
RAG-DOC-050	Task 3: 기존 beauty 청크 재임베딩 CLI	MD
RAG-DOC-051	Task 4: BM25·dense·hybrid 비교 검색	MD
RAG-DOC-052	Task 5: 고정 질의 평가와 결과 보고서	MD
RAG-DOC-053	SDD ledger — plan: docs/superpowers/plans/2026-10-20-rag-bge-m3-full-dataset-activation.md	MD
RAG-DOC-054	Task 1: Add safe whole-run BGE profile scope	MD
RAG-DOC-055	Task 2: Index every missing BGE vector with resume support	MD
RAG-DOC-056	Task 3: Route BGE queries through hybrid search and readiness	MD
RAG-DOC-068	BGE-M3 Dense + BM25 Comparison Implementation Plan	MD
RAG-DOC-069	test_items2 Full-Dataset BGE-M3 Activation Implementation Plan	MD
RAG-DOC-070	BGE-M3 dense 검색 전환 및 비교 설계	MD
RAG-DOC-071	test_items2 전체 BGE-M3 하이브리드 검색 활성화 설계	MD
RAG-DOC-101	Commerce + RAG Full-Flow Implementation Plan	MD

ID	원문 제목	형식
RAG-DOC-102	Commerce Frontend + RAG Full-Flow Integration Design	MD
RAG-DOC-103	SDD ledger — plan: /home/aiteam/projects/toss-ads-project/docs/superpowers/plans/2026-10-17-rag-required-intake.md	MD
RAG-DOC-104	Task 1: Enforce intake and Commerce price filtering in the RAG service	MD
RAG-DOC-105	Task 2: Add the Shopping Agent RAG tool and required clarification prompt	MD
RAG-DOC-106	Task 3: Require budget and use case in the direct RAG search screen	MD
RAG-DOC-190	Amazon Reviews RAG Service Integration Plan	MD
RAG-DOC-155	Amazon Reviews 백엔드 연동 설계	MD
RAG-DOC-189	RAG Evaluation and Full Index Plan	MD
RAG-DOC-187	Commerce + RAG Full-Flow Implementation Plan	MD
RAG-DOC-191	Commerce Frontend + RAG Full-Flow Integration Design	MD
RAG-DOC-188	RAG 공동 규격과 원본 근거 검증 구현 계획	MD
RAG-DOC-192	RAG 카테고리 안전 처리	MD
RAG-DOC-086	5432 RAG 인덱스 프로필 연결 계획	MD
RAG-DOC-087	전체 상품 RAG 카탈로그 프로필 설계	MD
RAG-DOC-145	Amazon Reviews API 구성 및 운영 기준	MD
RAG-DOC-146	Amazon Reviews PostgreSQL 운영 구현 계획	MD
RAG-DOC-147	Amazon Reviews RAG 구현 계획	MD
RAG-DOC-148	Amazon Reviews API 설계	MD
RAG-DOC-149	Amazon Reviews PostgreSQL 저장소 설계	MD
RAG-DOC-150	Amazon Reviews 하이브리드 RAG 검색 설계	MD
RAG-DOC-134	Required Intake Before Shopping RAG Search Implementation Plan	MD
RAG-DOC-135	Required Intake Before Shopping RAG Search	MD
RAG-DOC-045	RAG recommendation quality implementation	MD

08-architecture-integration

ID	원문 제목	형식
RAG-DOC-235	Product RAG Service	MD
RAG-DOC-057	Product RAG Backend	MD
RAG-DOC-058	product-rag-bge-m3-embeddings.sql	SQL
RAG-DOC-059	product-rag.sql	SQL
RAG-DOC-061	Product RAG Service	MD
RAG-DOC-067	RAG 검색의 현재 방향	MD
RAG-DOC-096	Product RAG Integration	MD
RAG-DOC-097	commerce-rag-demo.compose.yaml	YAML
RAG-DOC-098	격리된 전체 상품 Commerce RAG 데모	MD
RAG-DOC-099	Product RAG Service	MD
RAG-DOC-100	RAG Search Direction	MD
RAG-DOC-107	CORE_TASK_SCOPE — Shopping Brain + CS Agent	MD
RAG-DOC-108	최소 DB / Commerce State / Agent Tool 설계	MD
RAG-DOC-109	AI Commerce P0 Implementation Plan	MD
RAG-DOC-110	코디세이 AI 네이티브 Final Project 미션 요약	MD
RAG-DOC-111	프로젝트 컨텍스트 — 목표·방향·로드맵	MD
RAG-DOC-112	AI Commerce Environment	MD
RAG-DOC-113	핵심 와이어프레임 설계 — Shopping Brain + CS Agent	MD
RAG-DOC-114	Commerce Environment 감사 — 2026-10-07	MD
RAG-DOC-115	Implementation Decisions	MD
RAG-DOC-116	Verification Log	MD
RAG-DOC-117	Commerce RAG 데모	MD
RAG-DOC-118	화면 / Commerce Action ↔ 향후 Agent Tool — 누적 분석	MD
RAG-DOC-119	토스 AI Engineer 채용 공고 — 제공 원문	MD
RAG-DOC-185	RAG 진행 근거 — 2026-10-15	MD
RAG-DOC-186	RAG 작업 진행 현황 — 공유용	MD
RAG-DOC-214	RAG 진행 근거 — 2026-10-15	MD
RAG-DOC-179	Amazon Reviews RAG 서비스	MD

ID	원문 제목	형식
RAG-DOC-183	RAG 세 산출물 통합 결정	MD
RAG-DOC-184	RAG 전체 흐름과 방향	MD
RAG-DOC-180	격리된 Commerce RAG 데모	MD
RAG-DOC-182	RAG 검색 근거와 Agent 연동 개선 제안	MD
RAG-DOC-075	Codyssey Final Toss Backend	MD
RAG-DOC-076	LangChain HTTP retrieval	MD
RAG-DOC-077	LangChain 구성도 — HTTP 검색 연결 후	MD
RAG-DOC-081	Product RAG Backend	MD
RAG-DOC-082	product-rag.sql	SQL
RAG-DOC-084	Product RAG Service	MD
RAG-DOC-085	RAG Search Direction	MD
RAG-DOC-139	Toss Final Project	MD
RAG-DOC-142	amazon-reviews-postgres.yml	YML
RAG-DOC-143	LangChain HTTP retrieval	MD
RAG-DOC-144	Amazon Reviews'23 API 명세	MD
RAG-DOC-120	Toss Ads AI Project	MD
RAG-DOC-131	product-rag-postgres.yml	YML
RAG-DOC-136	RAG 데이터 출처 범위	MD
RAG-DOC-137	rag-overview-2026-10-17.pdf	PDF
RAG-DOC-001	Product RAG recommendation quality	MD
RAG-DOC-003	product-rag.sql	SQL
RAG-DOC-026	추천 품질 개선 구현	MD
RAG-DOC-027	test_items2 RAG API 적용 기록	MD
RAG-DOC-044	rag-recommendation-quality-summary-2026-10-19.pdf	PDF

09-team-rules

ID	원문 제목	형식
RAG-DOC-060	공통 작업 규칙과 RAG 적용 상태	MD
RAG-DOC-213	공통 작업 규칙과 RAG 적용 상태	MD
RAG-DOC-181	공통 작업 규칙과 RAG 적용 상태	MD
RAG-DOC-078	공통 작업 규칙 참조	MD
RAG-DOC-083	공통 작업 규칙과 RAG 적용 상태	MD
RAG-DOC-151	팀 공통 Git 협업 기준 위치	MD
RAG-DOC-046	팀 공통 Git 협업 기준 — 정본	MD