test_items2/beauty 검색 비교: BM25 와 BGE-M3

작성일: 2026-10-20

상태: 탐색 평가 완료

요약

기존 `test_items2/beauty` 의 96 토큰 청크 78,595 개를 다시 만들지 않고, 각 청크의 기존 `embedding_text` 로 BGE-M3 1,024 차원 벡터를 추가했다. 같은 긍정 질의 10 개와 범위 밖(OOD) 질의 2 개로 다음 검색을 비교했다.

1. BM25 단독
2. BM25 + BGE-M3 dense 하이브리드 (상품 단위 RRF, `k=60`)
3. BGE-M3 dense 단독

이 표본에서는 하이브리드가 Hit@1, Macro Recall@5, Macro MRR@5, Macro Precision@5 에서 가장 높았다. 다만 정답 라벨이 규칙 생성 후 사람 검수를 거치지 않았고 긍정 질의도 10 개뿐이므로, 운영 정확도나 일반적인 모델 우열로 해석하면 안 된다. 세 구성 모두 OOD 질의 2 개에 결과를 반환했다. 검색 결과를 거절하는 임계값은 이번에 평가하지 않았다.

데이터와 모델

항목	값
데이터베이스	`toss_rag`, 포트 `5432`
run ID	`e925490f-4f34-4c03-9248-eb9ebdfcde48`
데이터 버전	`test_items2:v6.1-review-refined:sha256=94681a28271ca9b1:products=1500:reviews=46100`
카테고리	`beauty`
평가 범위	상품 781 개, 리뷰 34,545 개, 청크 78,595 개
청커	`source-evidence-token-v2:max_tokens=96`
임베딩 모델	`BAAI/bge-m3`, revision `5617a9f61b028005a4858fdac845db406aefb181`

항목	값
BGE-M3 벡터	1,024 차원, 문서·질의 최대 길이 128 토큰, CPU 8 threads
검색 깊이	BM25 와 dense 각각 top 20, 평가 지표 top 5

이번 BGE-M3 벡터는 기존 384 차원 MiniLM 벡터와 별도 테이블·프로필에 저장했다. 기존 청크, MiniLM 데이터, 활성 인덱스, 서비스 기본 검색 설정은 변경하지 않았다.

전체 지표

지표	BM25 단독	BM25 + BGE-M3	BGE-M3 dense 단독
Hit@1	60% (6/10)	**80% (8/10)**	**80% (8/10)**
Hit@5	**100% (10/10)**	**100% (10/10)**	90% (9/10)
Macro Recall@5	0.5403	**0.6064**	0.4694
Macro MRR@5	0.7667	**0.8833**	0.8333
Macro Precision@5	0.4000	**0.5400**	0.5000
OOD 결과 반환	2/2	2/2	2/2

Recall 은 각 질의의 기대 상품 중 top 5 에 든 비율을 구한 뒤 10 개 긍정 질의에 대해 평균했다. Precision@5 는 실제 결과가 5 개 미만이어도 분모를 항상 5 로 사용했다. OOD 행은 정답 상품이 없는 검색에서 결과가 반환된 횟수다.

질의별 결과

아래의 `a/b · 순위 n`은 기대 상품 `b`개 중 top 5 에 `a`개가 포함됐고, 첫 기대 상품이 `n`위였다는 뜻이다. `—`는 top 5 에 기대 상품이 없다는 뜻이다.

질의	기대 상품 수	BM25	하이브리드	Dense
트러블 진정 세럼 추천	12	1/12 · 순위 1	2/12 · 순위 1	4/12 · 순위 1
블러셔 추천	8	3/8 · 순위 1	4/8 · 순위 1	4/8 · 순위 1
아이라이너 추천	5	4/5 · 순위 1	5/5 · 순위 1	4/5 · 순위 1
눈썹용 브로우 추천	5	4/5 · 순위 1	5/5 · 순위 1	4/5 · 순위 1
입술 보습 립밤 추천	3	3/3 · 순위 2	2/3 · 순위 1	1/3 · 순위 1
건조할 때 바르는 수분 크림 추천	24	1/24 · 순위 3	3/24 · 순위 1	3/24 · 순위 3
트러블 여드름 피부 토너패드 추천	4	1/4 · 순위 3	2/4 · 순위 1	3/4 · 순위 1
SPF 50 비비크림 추천	1	1/1 · 순위 1	1/1 · 순위 3	0/1 · —
우르오스 올인원 스킨밀크 200ml	1	1/1 · 순위 1	1/1 · 순위 1	1/1 · 순위 1
민감하고 건조한 피부 장벽 보습 크림	19	1/19 · 순위 2	2/19 · 순위 2	1/19 · 순위 1

OOD 질의 `게임용 기계식 키보드 적축 추천`과 `세탁세제 추천`도 각각 세 구성에서 top 5 결과를 받았다. 현재 비교 경로는 결과를 항상 top 5 까지 보여주며, OOD 를 알아내거나 결과를 거절하지 않는다.

질의 및 검색 시간

단위는 밀리초이며, 12 개 질의를 한 번씩 실행한 결과다. 검색 시간은 BGE-M3 질의 임베딩 시간을 제외한다.

측정값	BM25 단독	BM25 + BGE-M3	BGE-M3 dense 단독
질의 임베딩 p50 / p95	—	70.544 / 122.615	71.472 / 102.733
검색 p50 / p95	54.520 / 67.430	81.858 / 3,266.474	702.144 / 772.439

표본이 12 개라 p95 는 한두 번의 긴 요청에 크게 좌우된다. 하이브리드 검색 p95 가 3.27 초로 측정됐으므로, 이 값은 재측정과 지연 구간 분석 없이 운영 성능으로 일반화하지 않는다. 부하 테스트나 반복·워밍업을 포함한 SLA 측정은 이번 범위에 없다.

BGE-M3 문서 벡터 적재

측정값	결과
전체 대상 청크	78,595
이번 재개 구간 시작 시 이미 있던 벡터	3,360
이번 구간에서 임베딩한 청크	75,235
문서 임베딩 시간	10,720.950 초 (약 2 시간 58 분 41 초)
이번 구간 전체 경과 시간	11,339.386 초 (약 3 시간 8 분 59 초)
순수 임베딩 처리량	초당 7.018 청크
현재 구간 모델 로드 시간	4.051 초
임베딩 프로세스 최대 메모리	2,452.04 MB

이미 있던 3,360 개 벡터는 앞선 중단 실행에서 저장된 것으로, 두 번의 중단 실행 시간은 위 수치에 포함되지 않는다. 이번 구간의 시간도 전체 첫 실행부터 완료까지의 총 시간이 아니다. 검색 비교에는 기존 벡터 3,360 개를 포함한 78,595 개 전체를 사용했다.

평가 중 발견한 BM25 실행 오류

평가 중 반복 검색에서 ParadeDB 가 `Unsupported query shape` 오류를 반환했다. DB `5432/toss_rag` 에서 같은 BM25 SQL 을 기본

Psycopg 자동 준비 설정으로 40 회 실행했을 때 3 회 실패했고, 해당 실행에 `prepare=False`를 지정한 경우 40 회 모두 성공했다. 이에 BM25 쿼리만 자동 준비에서 제외하고 회귀 테스트를 추가했다. 수정 뒤 고정 질의 12 개를 3 회 반복한 36 회 검색과 전체 평가가 완료됐다.

해석과 한계

- 이 고정 질의 집합에서 하이브리드는 BM25 단독보다 Hit@1 이 20%p 높고 Macro Recall@5 가 0.0661 높았다. 10 개 질의 중 2 개가 Hit@1 결과를 바꿀 수 있는 작은 표본이다.
- Dense 단독은 Hit@1 에서 하이브리드와 같았지만 Hit@5 와 Macro Recall@5 는 더 낮았다. 따라서 현재 결과만으로 BM25 를 제거하는 결정을 내리지 않는다.
- 기대 상품 라벨은 상품 유형·제목 규칙으로 만들었으며 사람이 검수하지 않았다. 관련성 판정이 불완전하거나 질의 의도를 충분히 대표하지 않을 수 있다.
- 긍정 질의는 10 개, OOD 질의는 2 개다. 이는 일반 정확도, 카테고리 전반 성능, 운영 검색 품질의 추정치가 아니다.
- 두 OOD 질의에서 모두 결과를 반환했지만, 이 실험은 무응답 임계값이나 안전한 거절 정책을 평가하지 않았다.
- 답변 생성기, 리랭커, BGE-M3 sparse/ColBERT 검색은 비교하지 않았다.
- BGE-M3 는 별도 임베딩 컴포넌트로 추가했으며, 이번 측정만으로 서비스 검색 설정을 전환하지 않았다.

산출물

- 질의별 평가 결과 JSON
- BGE-M3 벡터 적재 요약 JSON
- 고정 질의 fixture