GROUND ANSWERS · BETTER CHOICES

근거를 찾고,
선택을 돕는 RAG

일반 문서 참고형과 상품 추천형 RAG의 차이,
현재 모델과 시스템 구성을 한 번에 정리합니다.

12 SLIDES

현재 기준 · test_earphones 합성 데모

01 문서 RAG

02 상품 RAG

03 두 방식 비교

04 모델

05 시스템

한 번의 질문, 다섯 개의 설계 포인트

두 RAG 활용 방식에서 시작해 모델과 현재 시스템까지 이어집니다.

01

USE CASE

일반 문서 참고형 RAG

문서 근거로 답하기

02

USE CASE

상품 추천형 RAG

상품·리뷰에서 후보 찾기

03

COMPARISON

두 방식 비교

목표와 출력의 차이

04

MODEL

모델과 선택 이유

검색과 대화 역할 구분

05

SYSTEM

전체 시스템 구성

데이터부터 결과까지

핵심 질문 · 검색은 어디까지 하고, 추천 판단은 누가 맡는가?

일반 문서 RAG는 근거를 찾아 답을 구성합니다

규정·매뉴얼·FAQ처럼 문서에 답이 들어 있는 질문에 잘 맞는 기본 흐름입니다.

01
질문
질문을 받는다
예: 연차는 언제부터 사용할 수 있나요?

→

02
문서
원문 자료를 모은다
규정 · 안내서
FAQ · 업무 가이드

→

03
분할·색인
문단 단위로 찾을 준비
문단 / 절 + 출처
키워드와 벡터 색인

→

04
검색
관련 근거를 가져온다
질문과 가까운
문단을 순위화

→

05
답변
근거를 바탕으로 응답을 쓴다
LLM이 요약하고
출처를 함께 표시

ANSWER + SOURCE

연차는 입사 3개월 후부터 사용할 수 있습니다.

근거 · 인사 규정 §12 / 개정일 2026.08

잘 맞는 질문

규정 · 절차 · 사실 확인

함께 관리할 것

문서 최신성 · 근거 누락 · 인용 정확도

참고: RAG 공통 개념을 설명하는 예시 흐름. 현재 이어폰 검색 데모의 답변 생성 경로와는 구분합니다.

문서 RAG 품질은 근거와 답변의 연결에서 결정됩니다

문서 분할, 검색, 답변 단계를 각각 점검해야 근거 없는 확장을 줄일 수 있습니다.

01 · INDEX

문서 구조와 버전 보존

문서명 · 조항 · 시행일
문단과 출처 메타데이터를 유지

02 · RETRIEVE

질문에 맞는 근거 검색

키워드와 의미 기반 검색
문서 유형 · 시점 조건 반영

03 · GENERATE

찾은 근거 안에서 답변

검색 구절을 답변 문맥에 넣고
문장과 출처를 연결

자주 생기는 실패

- 개정 문서가 색인에 반영되지 않음
- 분할 과정에서 예외 조항이 끊김
- 근거 문단은 맞지만 답이 범위를 넘음

운영에서 확인할 것

- 문서 버전과 시행일을 결과에 표시
- 질문별 출처 적합도와 인용 위치 점검
- 근거가 부족하면 보류하거나 되묻기

일반 문서 RAG의 설계 원칙 예시. 현재 이어폰 검색 데모의 동작 설명과 구분합니다.

상품 추천 RAG는 상품과 리뷰에서 후보 근거를 찾습니다

상품 설명과 후기를 청크로 저장하고, 찾은 근거를 상품 ID에 연결합니다.

질문 예시 통화와 음악 감상에 쓸 이어폰, 배터리 후기도 보고 싶어요

01
SOURCE
상품 설명 + 리뷰
기능·스펙·리뷰
상품 ID / 출처 보존

→

02
RETRIEVAL
BM25 + 의미 검색
단어 일치와
뜻의 유사도를 함께

→

03
FUSION
상품별 RRF 순위
두 검색 채널의
순위를 합쳐 정렬

→

04
EVIDENCE
후보 + 원문 근거
상품 후보별
최대 3개 근거

→

05
COMMERCE
ID로 정보 보강
가격 · 재고
옵션 · 배송비 포함

RAG
관련 후보와
상품·리뷰 근거

COMMERCE
최신 가격 · 재고
옵션 · 예산 필터

AGENT
필요 정보 확인
근거를 쉬운 말로 설명

가격 조건은 검색 API가 아니라 Commerce 카탈로그의 옵션 가격과 배송비로 확인합니다.

현재 데모의 검색 결과는 추천 후보와 원문 근거입니다. 정답 확률이나 모든 조건 충족의 보증은 아닙니다.

상품 추천은 후보 검색 뒤에 조건을 다시 확인합니다

검색 순위와 실제 구매 가능 조건을 분리해 처리하는 것이 현재 설계의 핵심입니다.

검색 입력 **사용 목적 + 질문**

예산은 Commerce 단계에서 확인

01
RETRIEVE
BM25 + Vector
단어 일치와 의미 검색
각 채널 후보 최대 20개

→

02
MERGE
상품 단위 RRF
각 채널에서 상품별
최고 순위를 결합

→

03
EVIDENCE
후보별 근거
상품별 1–3개
원문 근거 반환

→

04
CATALOG
Commerce 조회
같은 product_id로
가격 · 옵션 · 재고 조회

→

05
FILTER
예산 확인
옵션 가격 + 배송비가
총예산 이내인지 확인

리뷰 요청

리뷰 전용 검색 채널을 더해 후기 근거를 보강합니다.

해석 주의

RRF 점수는 정답 확률이 아니며, 검색만으로 모든 필수 조건이 검증되지는 않습니다.

기준: 현재 이어폰 데모 설정. 상품·리뷰 50개·1,000개는 재현용 합성 데이터입니다.

두 방식은 같은 RAG 원리를 쓰지만 결과 단위가 다릅니다

문서 RAG는 답변에 근거를 붙이고, 상품 RAG는 상품 후보에 근거를 붙입니다.

	일반 문서 참고형 RAG	상품 추천형 RAG
목표	문서 근거를 찾아 질문에 답한다	관련 상품 후보와 추천 근거를 찾는다
데이터	규정 · 매뉴얼 · FAQ 문단 / 절	상품 설명 · 스펙 · 리뷰 상품 ID로 연결
검색 단위	관련 문단 / 문서 순위	근거 청크를 찾고 상품 단위로 순위를 결합
결과	답변 문장 + 출처 인용	상품 카드 + 원문 근거 가격 · 재고 · 옵션 보강
주요 검증	문서 최신성 · 인용 정확도 질문별 근거 적합성	상품 / 카테고리 연결 가격 · 조건 · 리뷰 출처

공통 기반 · 자료를 나눠 색인하고, 질문과 가까운 근거를 검색

질문과 출력이 달라서 평가 기준도 달라집니다

일반 문서 RAG는 답변의 근거성을, 상품 추천 RAG는 후보의 적합성과 판매 조건을 봅니다.

일반 문서 참고형 RAG

질문

연차는 입사 후 언제부터 사용할 수 있나요?

답변 + 문서 출처

입사 3개월 후부터 사용할 수 있습니다.
[인사 규정 · 제12조]

검증 · 답변 정확도 + 인용 출처

상품 추천형 RAG

질문

통화용 이어폰 중 배터리 후기가 좋은 상품 추천

상품 후보 + 원문 근거

상품 후보 카드
통화 · 배터리 관련 설명/후기 근거 + 가격 확인

검증 · 후보 적합도 + 근거 + 예산 조건

문서 RAG는 근거 문서에서 답을 만들고, 상품 RAG는 근거와 카탈로그 정보를 엮어 후보를 보여줍니다.

예시는 두 방식의 출력 차이를 설명하기 위한 구성입니다. 상품 리뷰는 합성 데모 데이터입니다.

검색 임베딩과 대화 모델은 역할이 다릅니다

RAG 검색 서비스가 실제로 쓰는 모델과, 별도 Agent에서 설정한 기본 모델을 구분합니다.

01 · RAG RETRIEVAL

검색용 임베딩

sentence-transformers/
paraphrase-multilingual-MiniLM-L12-v2

FASTEMBED | 384 DIMENSIONS | MAX 128 TOKENS

왜 사용하나

- 다국어 문장 임베딩으로 질문과 표현이 다른 설명·후기를 의미 기준으로 비교합니다.
- 384차원 벡터로 검색하고, 기본 청크는 96 tokens로 둡니다(모델 입력 상한 128).
- 초기 기본 후보로 설정되어 있으며 RAG_EMBEDDING_MODEL로 교체할 수 있습니다.

선정은 초기 선택 · 실제 데이터의 성능 우위가 입증된 것은 아닙니다.

02 · SHOPPING AGENT

응답 생성 LLM

OpenAI Responses API

코드 기본값 · gpt-6-luna

LLM_MODEL로 변경 가능

현재 동작 범위

- Live provider가 켜지면 대화와 tool 선택에 사용됩니다.
- 기본은 API 키가 없을 때 stub 모드이며, stub은 RAG를 호출하지 않습니다.
- RAG API 자체는 답변 문장을 만들지 않고 상품 후보와 근거를 돌려줍니다.

gpt-6-luna는 코드 기본값이며, 실제 실행 모델·우수성은 런타임과 평가로 확인해야 합니다.

출처: config.py / embeddings.py / config.ts / llm.ts · FastEmbed model list · Hugging Face model card.

색인은 상품·리뷰 원문을 검색 가능한 근거로 바꿉니다

현재 이어폰 데모는 합성 상품 50개와 합성 리뷰 1,000개를 기준으로 색인합니다.

01 SOURCE

test_earphones

상품 50개 · 리뷰 1,000개
리뷰는 한국어 합성 템플릿

→

02 CHUNK

근거 단위로 분할

상품 ID · 필드 · 출처
원문 위치와 버전 유지

→

03 EMBED

FastEmbed

다국어 임베딩 생성
기본 청크 96 tokens

→

04 INDEX

RAG PostgreSQL

pg_search BM25
pgvector 벡터 검색

RAG 색인에 저장

텍스트 청크 · 임베딩 벡터 · 상품 ID

출처 종류 · 원문 필드 · 문서 버전과 위치를 함께 저장해
검색 결과를 원래 상품/리뷰 근거까지 추적합니다.

Commerce 카탈로그는 별도 조회

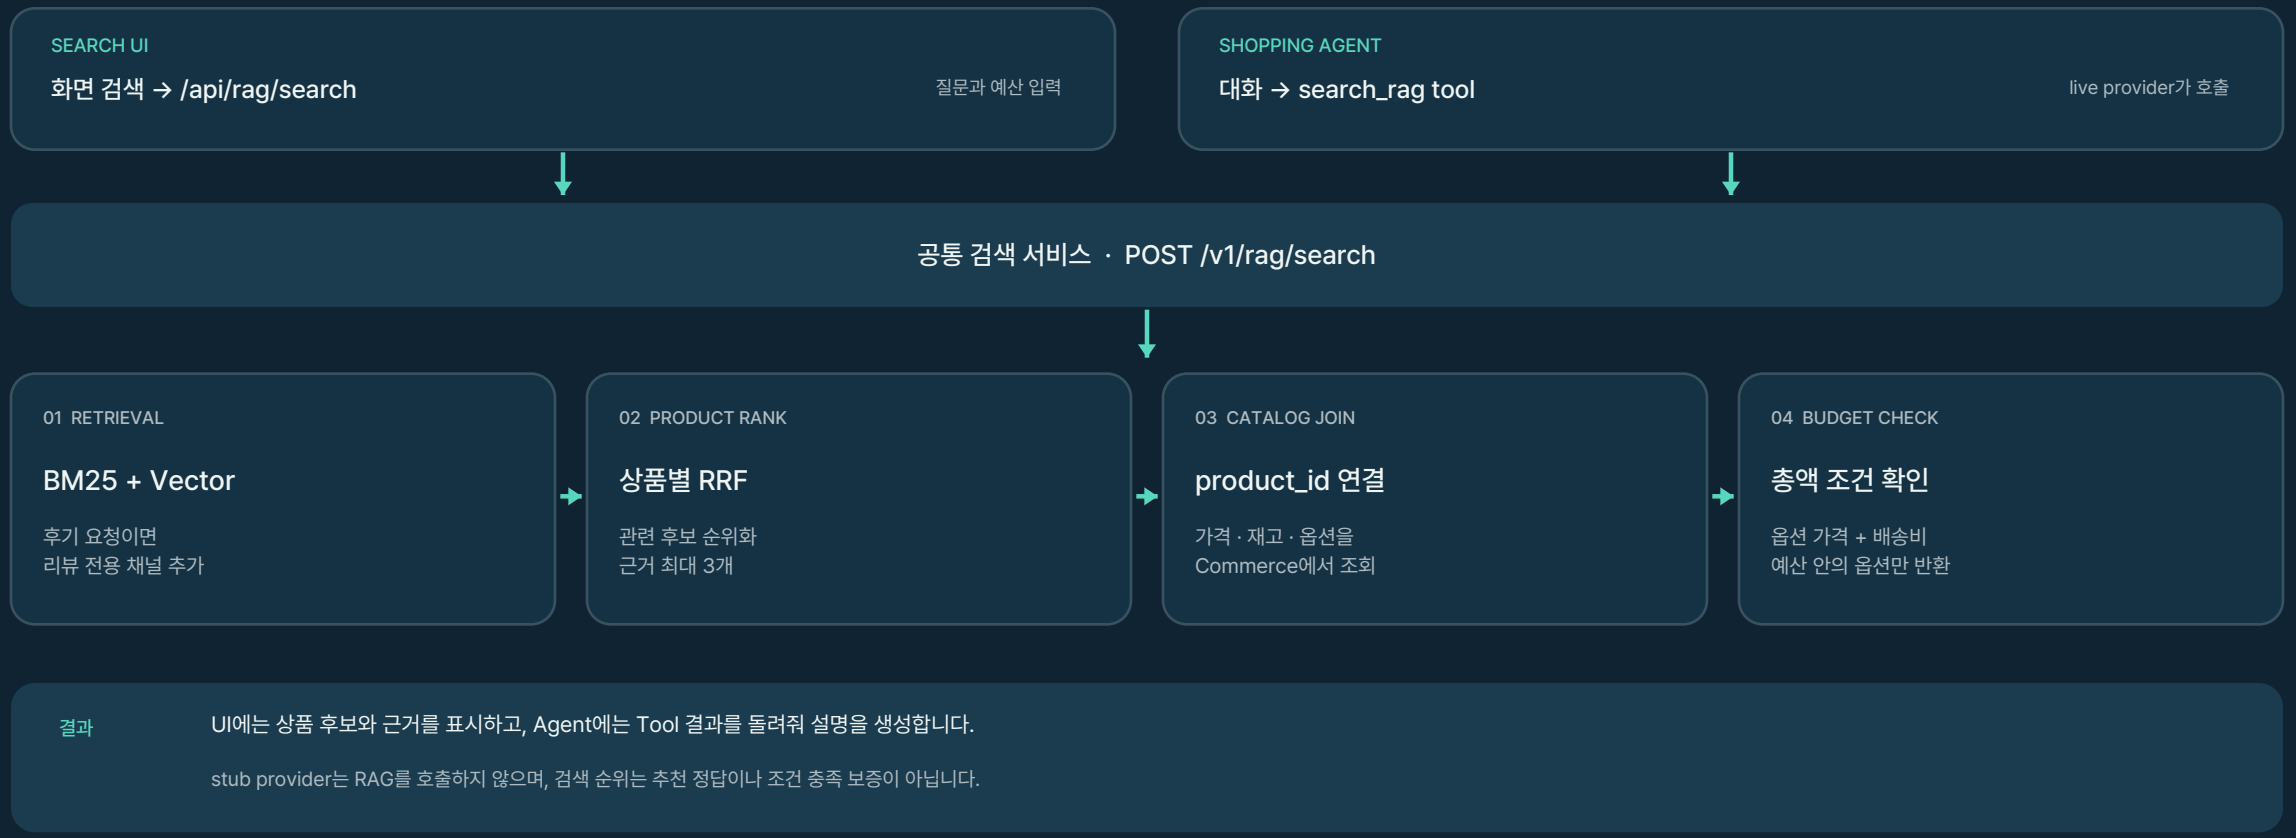
가격 · 재고 · variant는 색인 근거와 분리

같은 product_id로 최신 판매 정보를 다시 읽습니다.
색인된 설명이나 리뷰가 가격·재고의 기준은 아닙니다.

기준: seed_earphones_test.py · commerce-rag-integration · test_earphones 자료는 실제 구매자 리뷰가 아닙니다.

검색 UI와 Agent는 같은 RAG API를 활용합니다

요청 경로는 다르지만 검색 근거를 만든 뒤 Commerce 정보로 후보를 확인합니다.



결과

UI에는 상품 후보와 근거를 표시하고, Agent에는 Tool 결과를 돌려줘 설명을 생성합니다.

stub provider는 RAG를 호출하지 않으며, 검색 순위는 추천 정답이나 조건 충족 보증이 아닙니다.

기준: commerce-storefront/src/rag-search.ts · src/agent.ts · RAG retriever.py. Agent tool 호출은 live provider 설정이 필요합니다.

핵심은 '검색'과 '최종 추천 판단'을 분리하는 것입니다

RAG가 찾은 근거를 Commerce 데이터와 Agent 설명에 연결합니다.

지금 설명할 수 있는 것

- 50개 상품 · 1,000개 합성 리뷰로 흐름을 재현
- 키워드(BM25) + 의미(Vector) 검색, RRF로 상품 순위 결합
- 상품 ID로 Commerce 가격 · 재고 · 옵션을 다시 조회

발표에서 구분할 한계

- 합성 리뷰는 실제 구매자 평판이나 판매 성과가 아님
- 검색 순위 점수는 정답 확률이 아니며 모든 조건 충족도 아님
- Agent 답변은 live provider가 설정된 경우에만 실행됨

RAG

후보와 근거를 찾는다

COMMERCE는 가격·재고를 확인하고, Agent는 조건을 정리해 근거를 설명한다.

범위: 현재 test_earphones 데모 · LLM 기본값은 코드에서 확인했으며 실제 런타임 provider / model은 별도 확인 대상입니다.